Zadanie 1: Korpusy anotowane oraz osadzenia słów i tekstów

PolEmo 2.0 – anotacja, zgodność anotatorów, osadzenia zdań

Aleksandra Hendrysiak, Jan Poręba, Bartosz Procki, Igor Sala; Grupa lab. 4 (17:05)

1 Zakres i dane

Sprawozdanie obejmuje Zadanie 1 część I oraz część II. Kod i wyniki znajdują się w repozytorium: https://github.com/JanP2002/NLP_Lab.

Użyto zdaniowej wersji korpusu PolEmo 2.0 (recenzje hoteli, lekarzy, uczelni i produktów; etykiety POZ, NEG, NEU, AMB). Po usunięciu 39 powtórzeń zostało 45 935 zdań (średnio 17,9 tokenów); rozkład etykiet jest niezrównoważony (NEG 36,8%, POZ 26,7%, NEU 24,5%, AMB 12,0%). Do anotacji wylosowano dwie rozłączne próbki po 100 zdań (po 25 z każdej klasy etykiety korpusu, zdania 5–40 tokenów, bez zdań przykładowych z wytycznych); anotatorom pokazano je bez etykiet korpusu.

2 Część I: anotacja

2.1 Procedura

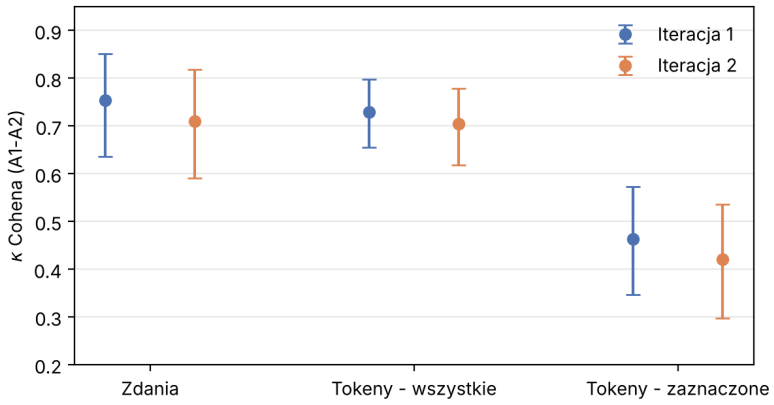
Do realizacji zadania, zastosowana została procedura 2+1: dwie osoby (A1, A2) anotowały niezależnie całą próbkę w arkuszach, a trzecia osoba (superanotator) rozstrzygała zdania, w których ich etykiety się różniły. Anotacja miała dwa poziomy: *etykieta zdania* (POZ, NEG, NEU, AMB) oraz *etykiety słów*: wyrażenia nacechowane (WYR_POZ, WYR_NEG) i modyfikatory (WZM – wzmocnienie, OSL – osłabienie, ODW – odwrócenie). Anotatorzy pracowali niezależnie, w osobnej kolejności zdań, według krótkiej notatki z wytycznymi (wersja 1).

2.2 Zgodność anotatorów i porównanie iteracji

Zgodność liczono kappą Cohena i kappą Fleissa (przy dwóch anotatorach niemal identyczne) na poziomie zdań, wszystkich słów oraz słów zaznaczonych, czyli takich, którym co najmniej jedna osoba nadała etykietę; Przedziały ufności zostały wyznaczone bootstrapem po zdaniach. Wyniki obu iteracji zestawia tab. 1 i rys. 1.

Poziom	Miara	Iteracja 1 [CI]	Iteracja 2 [CI]	Δ	Δ [95% CI]
Zdania	Cohen	0,754 [0,64; 0,85]	0,710 [0,59; 0,82]	−0,044	[−0,209; 0,121]
	Fleiss	0,754 [0,64; 0,85]	0,709 [0,59; 0,82]	−0,044	[−0,210; 0,122]
Tokeny – wszystkie	Cohen	0,730 [0,66; 0,80]	0,705 [0,62; 0,78]	−0,025	[−0,139; 0,084]
	Fleiss	0,730 [0,66; 0,80]	0,705 [0,62; 0,78]	−0,025	[−0,140; 0,084]
Tokeny – zaznaczone	Cohen	0,463 [0,35; 0,57]	0,420 [0,30; 0,54]	−0,042	[−0,206; 0,123]
	Fleiss	0,462 [0,34; 0,57]	0,414 [0,29; 0,53]	−0,048	[−0,220; 0,121]

Tabela 1: Zgodność A1–A2 w iteracji 1 (wytyczne v1) i iteracji 2 (wytyczne v2); $\Delta = \kappa_2 - \kappa_1$ z 95% przedziałem ufności różnicy.



Rysunek 1: Kappa Cohena A1–A2 z 95% przedziałami ufności w obu iteracjach.

W iteracji 1 zgodność na zdaniach wyniosła 83,0% ($\kappa = 0{,}754$, znaczna), na wszystkich słowach $\kappa = 0{,}730$, ale na słowach zaznaczonych tylko $\kappa = 0{,}463$ (umiarkowana): anotatorzy zgadzali się co do oceny zdania lepiej niż co do tego, *które* słowa ją niosą. Najsłabiej zgodne były etykiety OSL i WYR_NEG oraz klasa zdań NEG.

Wytyczne v2. Analiza 17 rozbieżnych zdań (najczęściej NEG/NEU) wskazała kilka powtarzających się problemów, na które odpowiedziano w wersji 2: (i) *fakt a opinia* – sam opis niekorzystnego zdarzenia bez oceny to NEU; (ii) negatywna ocena jednego aspektu może wystarczyć do NEG; (iii) brak wyraźnej oceny to NEU; (iv) słowa zależne od kontekstu (*może*, *tylko*, *mało*, *słabo*) nie przesądzają o wydźwięku; (v) słowa oznacza się według funkcji w zdaniu oraz doprecyzowano AMB, negację i ironię.

Wynik iteracji 2. Zgodność *nie wzrosła*: κ na zdaniach spadła z 0,754 do 0,710, na wszystkich słowach z 0,730 do 0,705, na słowach zaznaczonych z 0,463 do 0,420. Wartości pozostają w tych samych kategoriach, a przedziały ufności różnic obejmują zero, więc przy 100 zdaniach nie ma podstaw do mówienia o istotnej poprawie ani pogorszeniu. W podziale na klasy (tab. 2) zgodność wzrosła dla NEG (z 0,661 do 0,805) i dla fragmentów WYR_NEG (0,604 → 0,698) oraz OSL (0,264 → 0,468), a spadła dla POZ i AMB (AMB ma tylko 6–10 zdań na osobę, więc ta wartość jest mało wiarygodna). Konflikty NEG/NEU stały się rzadsze (9 → 3), zgodnie z intencją reguły o fakcie i opinii, ale przybyło konfliktów POZ/NEU (4 → 7) i pojawiły się NEU/AMB (0 → 3). Może to być spowodowane tym, że nowe reguły przesunęły granicę ku NEU, ale kryterium „brak wyraźnej oceny" bywa nadal rozumiane różnie; na wynik wpływają też inna próbka i mała liczba zdań.

Klasa	κ iter. 1	A1/A2	κ iter. 2	A1/A2	$\Delta\kappa$
POZ	0,851	27/29	0,703	26/23	−0,148
NEG	0,661	22/24	0,805	23/24	+0,144
NEU	0,732	42/41	0,736	44/43	+0,003
AMB	0,784	9/6	0,423	7/10	−0,361

Tabela 2: Kappa Cohena dla każdej klasy zdań osobno (klasa kontra reszta); A1/A2 to liczby zdań danej klasy.

2.3 Rozstrzygnięcie konfliktów i zbiór finalny

Superanotator rozstrzygnął 17 (iteracja 1) i 20 (iteracja 2) rozbieżnych zdań; pozostałe zachowały wspólną etykietę. Powstał zbiór 200 zdań z uzgodnioną etykietą (*final*): POZ 54, NEG 46, NEU 83, AMB 17. Zgodność z etykietą korpusu wynosi 69,5% (tab. 3); największa różnica to zdania z etykietą korpusu AMB, z których 17 z 50 uznano za NEU. Kierunek zmian jest zgodny z nowymi regułami (brak wyraźnej oceny to NEU); etykieta *final* dotyczy zdania ocenianego bez kontekstu recenzji, a etykieta korpusu pochodzi z anotacji korpusu, więc różnice nie muszą oznaczać błędu żadnej ze stron.

gold ↓ / final →	POZ	NEG	NEU	AMB	razem
gold POZ	40	0	9	1	50
gold NEG	1	38	11	0	50
gold NEU	2	1	46	1	50
gold AMB	11	7	17	15	50
razem	54	46	83	17	200

Tabela 3: Etykieta korpusu (gold) a etykieta uzgodniona (final), 200 zdań.

2.4 Pozostała część zbioru i statystyki opisowe

Pozostała część zbioru nie została zanotowana. W ramach zadania zanotowano dwie próbki po 100 zdań (łącznie 200 zdań z uzgodnioną etykietą). Zgodność w iteracji 2 (κ Cohena na zdaniach 0,710, znaczna) pozwalałaby przejść do anotacji reszty zbioru, ale nie została ona wykonana.

Statystyki opisowe uzyskanego zbioru 200 zdań podają tab. 4 i 5. W obu próbkach dominuje NEU, a AMB jest rzadkie, przy czym w próbce 2 jeszcze rzadsze (6 zdań wobec 11). Długość zdań jest podobna (średnio 17,1 i 16,1 tokenów, łącznie 16,6; zakres 5–36). Wśród słów z etykietą przeważają wyrażenia nacechowane (WYR_POZ i WYR_NEG), a modyfikatory są rzadsze; OSL występuje tylko kilka razy na próbkę. Liczby oznaczonych słów różnią się nieco między anotatorami, co odpowiada umiarkowanej zgodności na słowach zaznaczonych.

Iteracja	POZ	NEG	NEU	AMB	razem	śr. tokenów	min	maks
1	27	22	40	11	100	17,1	5	36
2	27	24	43	6	100	16,1	5	35
razem	54	46	83	17	200	16,6	5	36

Tabela 4: Zbiór uzgodniony: rozkład etykiet zdań i długość zdań (liczba tokenów) w próbkach.

Etykieta słowa	iter. 1: A1	iter. 1: A2	iter. 2: A1	iter. 2: A2
WYR_POZ	88	77	95	77
WYR_NEG	54	53	56	43
WZM	29	31	19	16
OSL	9	6	11	6
ODW	17	15	20	23

Tabela 5: Liczba słów z daną etykietą fragmentu u każdego anotatora (przed rozstrzygnięciem).

3 Część II: Word Embeddings

W tej części porównano dwa modele word2vec różniące się korpusem uczącym: ogólny model IPI PAN i model wytrenowany na recenzjach PolEmo. Kod: `src/word_embeddings.py` (osadzenia), `src/word_tsne.py` (t-SNE), `src/word_neighbours.py` (najbliższe słowa), `src/word_report.py` (tabele i liczby do sprawozdania).

W ramach eksperymentu wykorzystano również model FastText do wyznaczania osadzeń słów występujących w anotowanym korpusie. Model ten, podobnie jak word2Vec, reprezentuje słowa za pomocą wektorów liczbowych, jednak dodatkowo uwzględnia n-gramy znakowe. Pozwala to uwzględniać budowę wyrazów i lepiej radzić sobie z różnymi formami fleksyjnymi oraz rzadkimi słowami.

3.1 Modele i pokrycie słownika

Osadzenia policzono dla wszystkich 1505 słów (2783 wystąpień; bez interpunkcji i samych liczb) z 200 zaanotowanych zdań. Porównano dwa modele word2vec [7] (skip-gram, 100 wymiarów), które różnią się korpusem uczącym:

- **IPI PAN** – gotowy model `nkjp+wiki-forms-all-100-skipg-ns` [8], uczony na pełnym Narodowym Korpusie Języka Polskiego i polskiej Wikipedii; wczytano 300 000 najczęstszych form;
- **PolEmo** – model wytrenowany przez nas w bibliotece gensim na wszystkich 45 935 zdaniach PolEmo (679 251 słów; słowa występujące co najmniej 3 razy, 15 epok); słownik 21 658 słów.

Wektor słowa wyszukiwano kolejno w formie małymi literami, w oryginalnej pisowni i z wielką literą na początku.

Model	słowa	wystąpienia	słowa zaanotowane	WYR_POZ (n=145)	WYR_NEG (n=86)	WZM (n=19)	OSL (n=13)	ODW (n=4)
IPI PAN	94,6%	97,1%	94,9%	94%	91%	100%	100%	100%
PolEmo	85,2%	92,0%	83,7%	86%	65%	95%	100%	100%

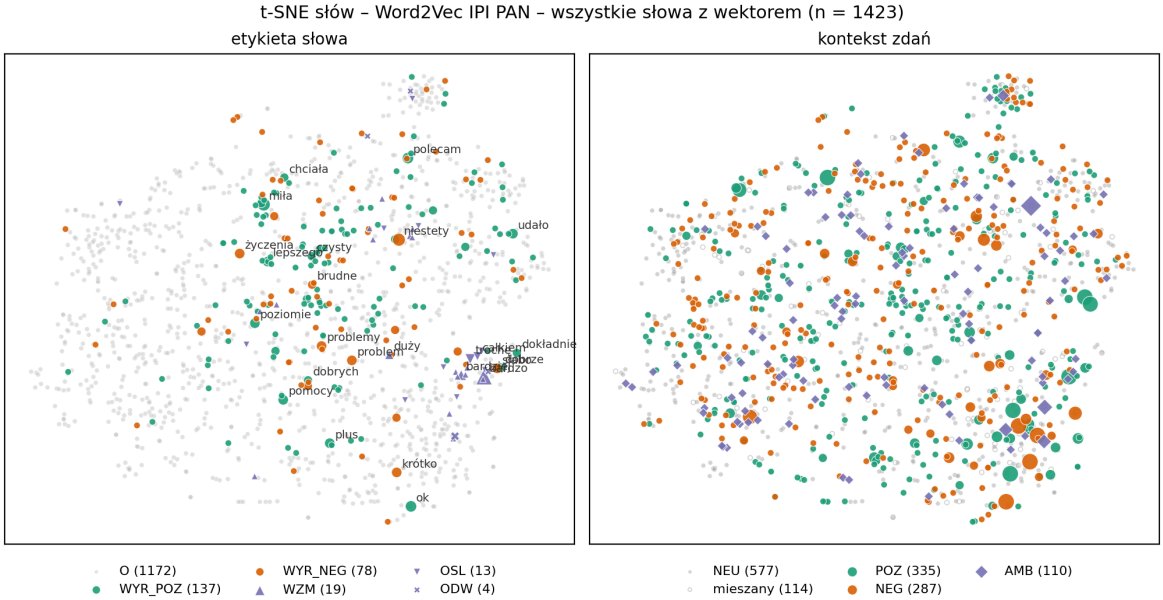
Tabela 6: Pokrycie słownika: odsetek słów (wystąpień) zaanotowanego korpusu, dla których model ma wektor. „Słowa zaanotowane" – z co najmniej jedną anotacją różną od O; kolumny etykiet – słowa o danej etykiecie (najczęstsza etykieta anotacji, jeśli co najmniej połowa anotacji słowa jest różna od O).

Brakujące wektory w modelu IPI PAN to głównie zapisy bez polskich znaków (*lazience* zamiast *łazience*), formy z cyframi (*2osobowym*), słowa rzadkie (*acellularne*).

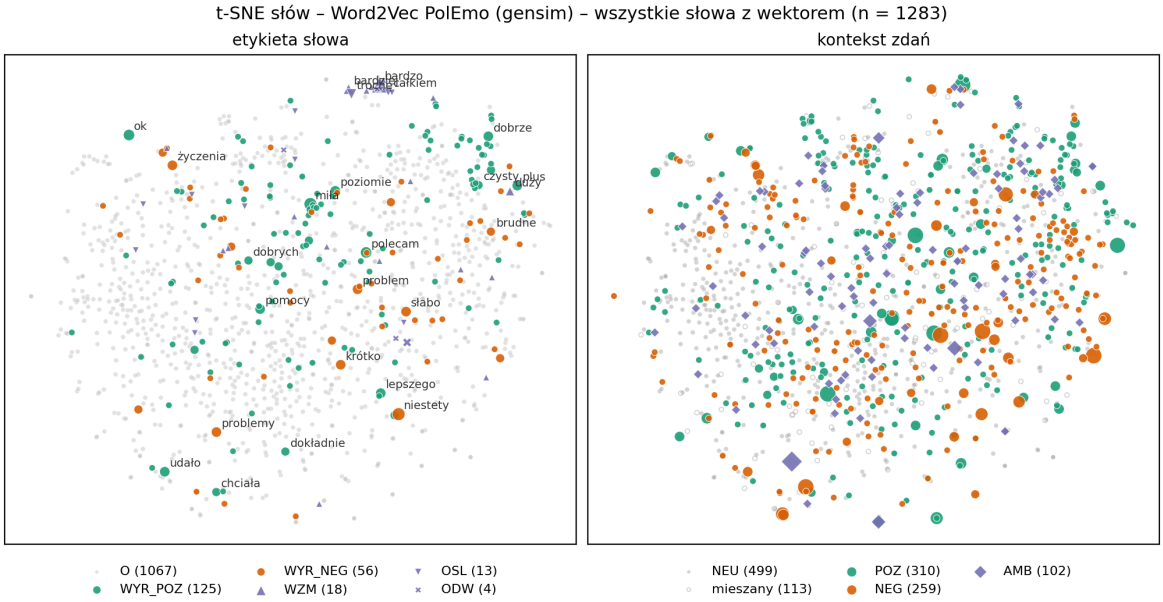
3.2 Wizualizacja t-SNE słów

Rys. 2 i 3 pokazują t-SNE (odległość kosinusowa) wszystkich słów z wektorem. Wersje interaktywne – po najechaniu na punkt widać słowo, jego etykietę, liczbę anotacji każdej etykiety i rozkład etykiet

zdań; lista rozwijana zmienia kolorowanie – są w repozytorium (`results/word_embeddings/tsne_words_*.html`). Ponieważ t-SNE zniekształca odległości, grupowanie sprawdzono też w oryginalnej przestrzeni (tab. 7).



Rysunek 2: t-SNE słów – word2vec IPI PAN. Kolor: etykieta słowa (lewy) i dominująca etykieta zdań, w których słowo wystąpiło (prawy); wielkość punktu rośnie z liczbą wystąpień, słowa bez etykiety są szarym tłem.



Rysunek 3: t-SNE słów – word2vec PolEmo. Kolor: etykieta słowa (lewy) i dominująca etykieta zdań, w których słowo wystąpiło (prawy); wielkość punktu rośnie z liczbą wystąpień, słowa bez etykiety są szarym tłem.

Model	Etykiety	n	czystość k-NN	losowo	sylwetka	sonda	losowo
IPI PAN	WYR_POZ / WYR_NEG	215	0,648	0,536	0,033	0,72	0,50
IPI PAN	POZ / NEG (zdania)	622	0,545	0,502	0,004	0,62	0,50
PolEmo	WYR_POZ / WYR_NEG	181	0,671	0,571	0,038	0,58	0,50
PolEmo	POZ / NEG (zdania)	569	0,559	0,504	0,006	0,62	0,50

Tabela 7: Czy etykiety grupują się w przestrzeni osadzeń (100 wymiarów, kosinus). Czystość k-NN – średni odsetek 10 najbliższych sąsiadów z tą samą etykietą; „losowo" – ta sama miara po przetasowaniu etykiet (1000 razy, $p < 0{,}01$ we wszystkich wierszach). Sonda – zrównoważona trafność regresji logistycznej (5-krotna walidacja krzyżowa).

3.3 Listy najbliższych słów

Dla 215 słów z etykietą różną od O, znanych obu modelom, wyznaczono 10 najbliższych słów (kosinus; tylko słowa z liter, z całego słownika modelu). Listy porównano miarami: odsetek wspólnych sąsiadów (także przy wyszukiwaniu tylko wśród 20 206 słów znanych obu modelom), korelacja Spearmana podobieństw między słowami zapytania w obu modelach (podobieństwo drugiego rzędu; dla całej macierzy $\rho = 0{,}27$), udział odmian słowa zapytania wśród sąsiadów oraz wydźwięk sąsiadów wyznaczony z etykiet korpusu PolEmo: $s = (\#\text{POZ} - \#\text{NEG})/\#\text{zdań}$ ze słowem (co najmniej 5 zdań, próg $\pm 0{,}1$).

Etykieta	n	wspólne@10	wspólne@10 (wspólny słownik)	ρ drugiego rzędu
WYR_POZ	125	8%	11%	0,32
WYR_NEG	55	9%	12%	0,26
WZM	18	16%	18%	0,24
OSL	13	8%	12%	0,23
ODW	4	8%	10%	0,41
wszystkie	215	9%	12%	0,29

Tabela 8: Zgodność list najbliższych słów: IPI PAN wobec PolEmo (średnie po słowach zapytania).

Model	odmiany	WYR_POZ: zgodny / przeciwny	WYR_NEG: zgodny / przeciwny
IPI PAN	13%	47% / 41%	67% / 17%
PolEmo	2%	59% / 32%	70% / 20%

Tabela 9: Charakter list: udział odmian słowa zapytania wśród sąsiadów (wspólny początek wyrazu) oraz wydźwięk sąsiadów słów WYR_POZ i WYR_NEG (odsetek sąsiadów z oceną s). Model PolEmo i miara s pochodzą z tego samego korpusu, więc jego wyższa zgodność wydźwięku jest częściowo „z założenia".

Słowo	Etykieta	IPI PAN	PolEmo
miła	WYR_POZ	sympatyczna, życzliwa, serdeczna, przyjemna, przemiła	pomocna, przemiła, uprzejma, sympatyczna, profesjonalna
polecam	WYR_POZ	odradzam$^{\otimes}$, polecasz, zalecam$^{\otimes}$, doradzam, radzę$^{\otimes}$	odradzam$^{\otimes}$, polecamy, polecić, polecę$^{\otimes}$, pragnie
dobrze	WYR_POZ	słabo$^{\otimes}$, świetnie, doskonale, znakomicie, wspaniale	fajnie, ładnie, świetnie, porządnie, estetycznie$^{\otimes}$
ok	WYR_POZ	około, tys, ponad$^{\otimes}$, blisko, tysięcy$^{\otimes}$	około, ponad$^{\otimes}$, min$^{\otimes}$, piechotą, prawie$^{\otimes}$
brudne	WYR_NEG	śmierdzące, cuchnące, dziurawe, gołe, podarte	wykładziny, kafelki, kurz, zniszczone, pleśń
problem	WYR_NEG	dylemat, kłopot, nierozwiązany, aspekt, argument	gorszy, błąd, kulinarnie, zdrowotny, pech
niestety	WYR_NEG	wprawdzie$^{\otimes}$, niemniej, bo, chyba, zresztą	szczęście, przyznać$^{\otimes}$, owszem, prawie, uwierzcie$^{\otimes}$
bardzo	WZM	dość, stosunkowo, niezwykle, niezbyt, zbyt	dość, niezbyt, niesamowicie, dosyć, naprawdę
trochę	OSL	troszkę, troszeczkę, ciut, odrobinkę, odrobinę	nieco, troszkę, zwyczajnie, ciągnie, wysłużone
nie	O	nigdy, ani, jednak, ale, gdyż	oj, wroce, odpisać, uważasz, niewiem

Tabela 10: Pięć najbliższych słów w obu modelach (pełne listy: `results/word_embeddings/neighbours_*.csv`, `knn_summary.md`). $^{\otimes}$ – wydźwięk sąsiada przeciwny do etykiety słowa zapytania.

Słowo	Najbardziej podobne słowa
miła	Miła, przemiła, sympatyczna, przesympatyczna, Przemiła
polecam	Polecam, polecama, POlecam, polecamOK, polecam8
dobrze	dobrz, świetnie, doskonale, bdobrze, idobrze
ok	Ok, ok.wielki, szybko.wielki, oki, polecam.wielki
brudne	śmierdzące, brudzone, Brudne, pobrudzone, niedomyte
problem	wproblem, Problem, dylemat, roblem, kłopot
niestety	stety, ale, niestet, niestetyy, niestey
bardzo	badzo, niezwykle, niesamowicie, Pardzo, baaaaaardzo
trochę	troszkę, troszeczkę, odrobinkę, ciutkę, rochę
nie	inie, Nie, ani, nigdy, przenigdzie

Tabela 11: Przykładowe listy najbliższych sąsiadów słów w modelu FastText.

Na podstawie tabeli 11 można zauważyć, że model FastText znajduje zarówno słowa o podobnym znaczeniu, np. „miła" i „sympatyczna", jak i różne formy fleksyjne oraz warianty zapisu, np. „trochę" i „troszkę" czy „bardzo" i „badzo". Wynika to z wykorzystania n-gramów znakowych, które pozwalają modelowi uwzględniać podobieństwo w budowie wyrazów. Jednocześnie wśród najbliższych sąsiadów pojawiają się literówki i nietypowe formy, co wskazuje, że podobieństwo wektorowe nie zawsze oznacza podobieństwo semantyczne. Wyniki sugerują, że FastText może być przydatny w analizie polskojęzycznych opinii, szczególnie w przypadku odmian fleksyjnych i niestandardowego zapisu słów.

3.4 Dyskusja

1. Czy osadzenia uczone na dużych korpusach dobrze odwzorowują znaczenie słów w korpusie dziedzinowym? Częściowo. Model IPI PAN zna 94,6% słów i 97,1% wystąpień naszego korpusu, w tym wszystkie zaanotowane modyfikatory (tab. 6); braki to głównie słowa

rzadkie, formy z cyframi i zapisy bez polskich znaków. Znaczenie ogólne oddaje trafnie (*lekarz* → *chirurg, internista*; *brud* → *smród, kurz*), ale jest to znaczenie słownikowe, a nie to, które słowo ma w recenzji: *miła* ma sąsiadów *sympatyczna, życzliwa*, a w modelu uczonym na PolEmo *pomocna, uprzejma, profesjonalna* (opinie o lekarzach); *brudne* ma w nim sąsiadów *wykładziny, kafelki, pleśń* (hotele). Model dziedzinowy płaci za to rozmiarem: słownik ma tylko 21 658 słów, a pokrycie spada do 85,2% (65% dla słów WYR_NEG). Oba modele traktują *ok* (w anotacji ocena pozytywna) jak skrót *około*.

2. Czy słowa związane z anotacją grupują się (pozytywne i negatywne)? Słabo. Na wykresach t-SNE (rys. 2 i 3) słowa WYR_POZ i WYR_NEG są wymieszane. W przestrzeni 100-wymiarowej słowa o tej samej etykiecie są sobie nieco bliższe niż przy losowym przypisaniu etykiet (czystość 10 najbliższych sąsiadów 0,648 wobec 0,536, tab. 7), ale nie tworzą skupisk (sylwetka 0,033); bliżej siebie leżą głównie słowa pozytywne (0,75), negatywne nie (0,47). Antonimy leżą blisko: $\cos(\text{dobry}, \text{zły}) = 0{,}73$, a 41% ocenionych sąsiadów słów pozytywnych ma wydźwięk negatywny (*polecam* → *odradzam*, *zadowolona* → *niezadowolona*). Wynika to ze sposobu uczenia: word2vec przewiduje kontekst słowa [7], a słowa o przeciwnym wydźwięku występują w tych samych kontekstach (*obsługa była miła / niemiła*). Wydźwięk zależy też od dziedziny i negacji; nawet anotatorzy oznaczali *nie* jako odwrócenie tylko w części zdań. Informacja o wydźwięku nie znika jednak całkiem: prosty klasyfikator odczytuje etykietę WYR_POZ / WYR_NEG z wektora IPI PAN z trafnością 0,72 (przy losowych etykietach 0,50), choć nie widać jej w sąsiedztwie słów. Wyraźniej słowa grupują się według funkcji: modyfikatory (*bardzo, bardziej, trochę, całkiem*) tworzą zwarte skupisko.

3. Na czym polegają różnice między listami najbliższych słów i z czego wynikają? Modele prawie się nie zgadzają: wspólnych jest średnio tylko 9% sąsiadów (12% przy wyszukiwaniu we wspólnym słowniku; tab. 8), a korelacja podobieństw między słowami zapytania wynosi 0,27. Różnica nie wynika więc z rozmiaru słowników, lecz z korpusu: model ogólny daje relacje słownikowe (synonimy, antonimy, wyrazy tej samej kategorii), model z recenzji – skojarzenia tematyczne (tab. 10). Mały korpus PolEmo (679 251 słów) daje szum dla rzadszych słów (*problem* → *kulinarnie, zdrowotny*). Model form IPI PAN częściej zwraca odmiany tego samego słowa (13% sąsiadów wobec 2%), a zapisy bez polskich znaków tworzą w nim osobne sąsiedztwa (*zaden* → *kazdy, zwykly*). Najbardziej zgodne są wzmacniacze (16% wspólnych sąsiadów), których użycie mało zależy od dziedziny.

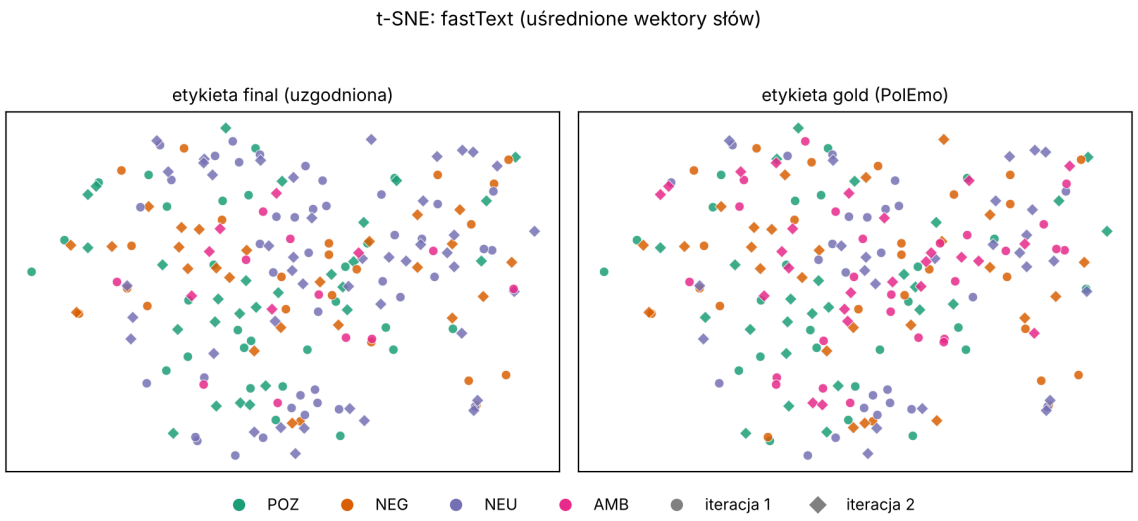
4. Jak można ulepszyć osadzenia dla tego zadania? (1) Dostosować model ogólny do dziedziny: dotrenować go na pełnych recenzjach PolEmo zamiast uczyć mały model od zera. (2) Dodać wiedzę o wydźwięku: *retrofitting* [9] z leksykonem (np. emocjonalną Słowosiecią), który odsuwa od siebie antonimy, albo osadzenia uczone z etykietami zdań PolEmo. (3) Użyć fastText [5], którego n-gramy znakowe radzą sobie z literówkami i zapisem bez polskich znaków. (4) Lematyzować tekst (albo użyć modeli *lemmas*), aby odmiany nie zajmowały list. (5) Traktować negację jako część jednostki (*nie_polecam*). (6) Sięgnąć po modele kontekstowe (np. HerBERT), które rozróżniają znaczenie słowa zależnie od zdania (*ok* jako ocena i jako skrót).

4 Część II: Text Embeddings

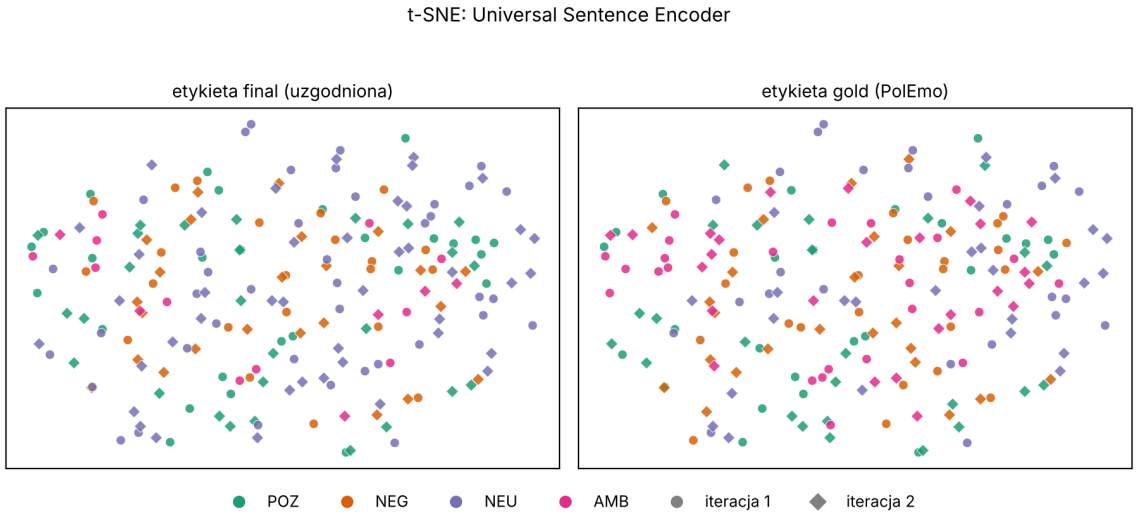
4.1 Osadzenia zdań i wizualizacja t-SNE

Wektory zdań policzone zostały dla 200 zdań z obu próbek, które mają etykiety korpusu, A1, A2 i uzgodnioną. Użyto dwóch modeli: **fastText** (model słów dla polskiego z CLARIN-PL, 100 wymiarów; wektor zdania to średnia wektorów jego słów) oraz **Universal Sentence Encoder** (wersja wielojęzyczna, 512 wymiarów, koduje całe zdanie). Jako punkt odniesienia dodany został **TF-IDF** (widzi tylko wspólne słowa). Uśrednione wektory **Word2Vec** (dwa modele z części Word Embeddings) opisuje osobno podrozdział 4.3.

Wizualizacje t-SNE (rys. 4, 5). Kolor oznacza etykietę, kształt punktu iterację.



Rysunek 4: t-SNE osadzeń fastText: kolor wg etykiety uzgodnionej (lewy) i korpusu (prawy).



Rysunek 5: t-SNE osadzeń Universal Sentence Encoder.

Obserwacje. W żadnym modelu klasy wydźwięku nie tworzą rozłącznych skupisk: punkty POZ, NEG, NEU i AMB są w dużej mierze wymieszane, a kolorowanie wg etykiety uzgodnionej i korpusu daje podobny obraz. Zgadza się to z miarami ilościowymi (pytanie 5): układ punktów wydaje się odzwierciedlać raczej treść zdań niż ich wydźwięk.

4.2 Analiza osadzeń i odpowiedzi na pytania

Odpowiedzi opierają się na ręcznie napisanych parach kontrolnych (parafrazy, przeciwny sens przy podobnych słowach, ten sam sens w różnej długości, pary niepowiązane; tab. 12), na parach zdań z korpusu oraz na klasyfikatorze wydźwięku uczonym na samych osadzeniach. Przy tak małych zestawach wnioski mają charakter ilustracji, a nie statystyki.

Kategoria par	fastText	USE	TF-IDF
parafraza	0,746	0,492	0,376
przeciwny sens, podobne słowa	0,859	0,794	0,744
przeciwny sens, te same słowa	0,892	0,924	0,770
ten sam sens, różna długość	0,604	0,191	0,389
kontrola: niepowiązane	0,506	0,111	0,004

Tabela 12: Średnie podobieństwo kosinusowe par kontrolnych według kategorii.

1. Czy są zdania uznane za podobne, ale różniące się znaczeniem? Tak. Pary o przeciwnym sensie i podobnych słowach mają wyższe podobieństwo niż prawdziwe parafrazy: 0,859 wobec 0,746 w fastText i 0,794 wobec 0,492 w USE; np. „miła"–„niemiła" daje 0,978 i 0,973. W korpusie najbliższe pary POZ–NEG w fastText (0,90–0,94) dotyczą tego samego tematu (lekarz, pacjent). W fastText negacja „nie" ma mały wpływ na średnią wektorów słów, a USE także wyraźnie nie rozróżnia takich par. Modele kodują więc głównie temat i słownictwo, nie wydźwięk.

2. Czy są zdania podobne znaczeniowo, a uznane za odległe, bo użyto innych słów? Tak. Parafrazy mają niskie podobieństwo: 0,746 (fastText), 0,492 (USE), 0,376 (TF-IDF); np. „Obsługa była bardzo miła i pomocna" i „Personel okazał się niezwykle uprzejmy i życzliwy" dają 0,681, 0,340 i 0,284. TF-IDF zawodzi najbardziej, bo widzi tylko wspólne słowa. USE ma niskie wartości, ale wyraźnie odróżnia parafrazy od zdań niepowiązanych (0,492 wobec 0,111), natomiast fastText uznaje za bliskie także zdania niepowiązane (0,506), bo wszystkie zdania są w nim do siebie podobne. W parach z korpusu USE trafnie zbliżył zdania o czasie („2 miesiące temu" i „od dwóch miesięcy"), ale pomylił dwie krótkie oceny o przeciwnym wydźwięku.

3. Czy zdania o różnej długości i podobnym sensie są traktowane podobnie? Nie w pełni. Krótkie zdanie i jego długa wersja o tym samym sensie mają podobieństwo 0,604 (fastText), 0,191 (USE) i 0,389 (TF-IDF), czyli mniej niż parafrazy, a w fastText tylko niewiele więcej niż zdania niepowiązane (0,506). Np. „Polecam ." i długa pochwała hotelu mają 0,662 w fastText i 0,078 w USE. Długie zdanie wnosi dużo dodatkowej treści, a w fastText uśrednianie zbliża je do przeciętnego wektora korpusu, więc podobne wydaje się niemal do wszystkiego. Zgodny wydźwięk nie wystarcza, by modele uznały takie zdania za podobne.

4. Czy długość zdania wpływa na podobieństwo i „wyrazistość" wektora? Tak. W fastText długie zdania (21–36 tokenów) są bliższe średniemu wektorowi korpusu niż krótkie (5–11 tokenów): podobieństwo do środka rośnie z 0,763 do 0,893, a średnie podobieństwo do innych zdań z 0,624 do 0,731 (korelacja rangowa 0,588); jednocześnie maleje długość wektora (30,3 → 27,8). Wynika to z uśredniania wektorów słów: w długim zdaniu wkłady się znoszą, a wektor staje się mniej wyrazisty. W USE efekt jest słabszy (korelacja 0,318). Wysokie podobieństwo w fastText może więc wynikać z samej długości zdań, a nie z podobnego sensu.

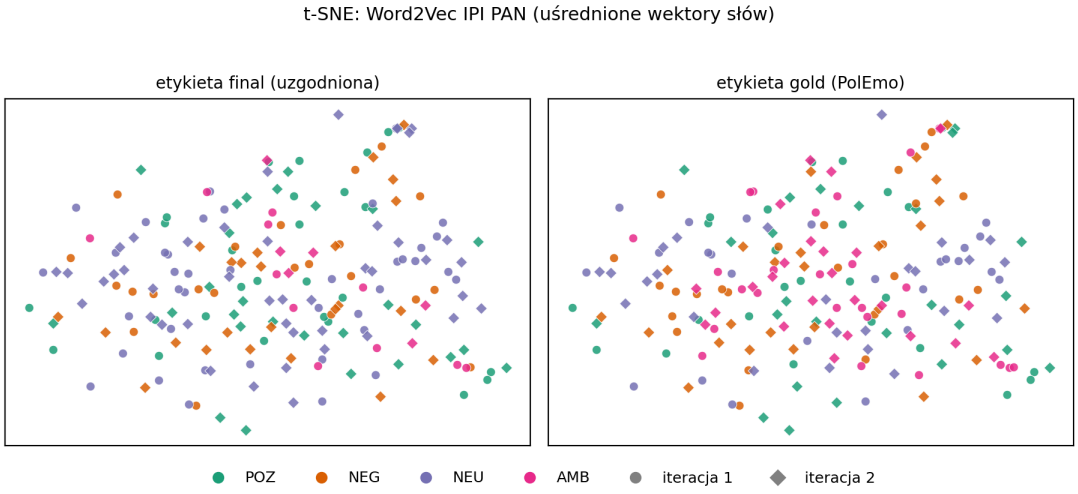
5. Czy osadzenia nadają się do anotowanego zadania (wydźwięk zdania)? Nie. Klasyfikator uczony na samych osadzeniach (tab. 13) osiąga dla etykiet uzgodnionych accuracy 0,505 (fastText) i 0,520 (USE) przy bazie większościowej 0,415 (zawsze NEU), czyli przewaga wynosi tylko 0,09–0,10. F1-Macro jest niskie (0,322 i 0,330), silhouette ujemne lub bliskie zeru (−0,123 i −0,013), co oznacza brak skupisk według wydźwięku. Klasyfikator wybiera głównie NEU (rozpoznaje je w 88–92%), klasę NEG rozpoznaje rzadko (9–15%), a AMB wcale (w zbiorze jest tylko 17 takich zdań). Na zbalansowanych etykietach korpusu USE wypada lepiej niż fastText (macro-F1 0,464 wobec 0,388), ale nadal słabo. Osadzenia mogłyby co najwyżej służyć jako cecha pomocnicza.

Model	Etykiety	n	accuracy	baza większ.	macro-F1	kNN-10	losowy	silhouette
fasttext	final	200	0,505	0,415	0,322	0,321	0,305	−0,123
	gold	200	0,395	0,250	0,388	0,282	0,250	−0,072
	A1	200	0,525	0,430	0,341	0,330	0,312	−0,117
	A2	200	0,495	0,420	0,291	0,304	0,308	−0,147
use	final	200	0,520	0,415	0,330	0,334	0,305	−0,013
	gold	200	0,465	0,250	0,464	0,321	0,250	−0,003
	A1	200	0,545	0,430	0,342	0,350	0,312	−0,013
	A2	200	0,540	0,420	0,364	0,336	0,308	−0,014
tfidf	final	200	0,490	0,415	0,318	0,335	0,305	−0,008
	gold	200	0,375	0,250	0,374	0,291	0,250	−0,006
	A1	200	0,485	0,430	0,299	0,356	0,312	−0,008
	A2	200	0,430	0,420	0,266	0,330	0,308	−0,009

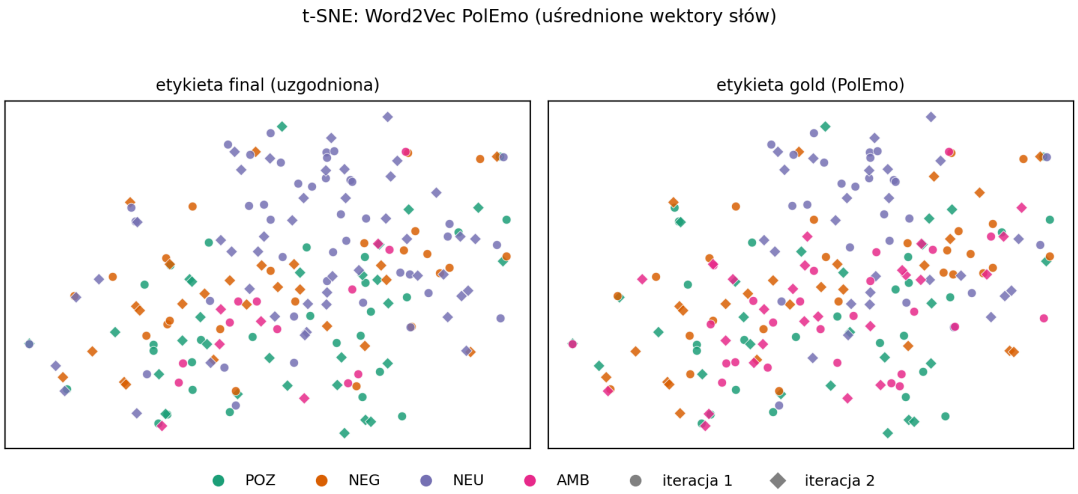
Tabela 13: Klasyfikacja wydźwięku zdania na samych osadzeniach (regresja logistyczna, 5-krotna walidacja krzyżowa). „Baza większ." to accuracy klasyfikatora zawsze wybierającego najliczniejszą klasę, „losowy" to losowanie zgodne z rozkładem klas (odniesienie dla kNN-10, czyli odsetka sąsiadów tej samej klasy).

4.3 Uśrednione wektory Word2Vec

Dodatkowo zbadano osadzenia zdań jako **średnią wektorów słów Word2Vec** dla dwóch modeli z części Word Embeddings (sekcja 3.1): ogólnego modelu IPI PAN i modelu wytrenowanego na recenzjach PolEmo (100 wymiarów). Słowa bez wektora pomijano; wektor ma średnio 96,7% słów zdania w modelu IPI PAN i 91,0% w modelu PolEmo, a żadne zdanie nie zostało bez wektora. Analizę wykonano tymi samymi funkcjami, parami kontrolnymi i miarami co dla fastText i USE (`src/text_analysis.py`), więc tabele porównują pięć modeli.



Rysunek 6: t-SNE osadzeń zdań: uśrednione Word2Vec IPI PAN; kolor wg etykiety uzgodnionej (lewy) i korpusu (prawy).



Rysunek 7: t-SNE osadzeń zdań: uśrednione Word2Vec PolEmo.

Na wykresach t-SNE (rys. 6 i 7) klasy są wymieszane, tak jak dla fastText i USE; w modelu PolEmo widać jedynie skupisko części zdań NEU.

Kategoria par	W2V IPI PAN	W2V PolEmo	fastText	USE	TF-IDF
parafraza	0,710	0,700	0,746	0,492	0,376
przeciwny sens, podobne słowa	0,882	0,877	0,859	0,794	0,744
przeciwny sens, te same słowa	0,950	0,927	0,892	0,924	0,770
ten sam sens, różna długość	0,578	0,658	0,604	0,191	0,389
kontrola: niepowiązane	0,428	0,431	0,506	0,111	0,004

Tabela 14: Pary kontrolne (tab. 12): średnie podobieństwo kosinusowe dla uśrednionego Word2Vec i modeli z poprzednich podrozdziałów.

1. Zdania uznane za podobne, a różne znaczeniowo. Tak, tak samo jak w fastText. Pary o przeciwnym sensie i podobnych słowach są bliższe niż parafrazy (0,882 wobec 0,710 w modelu IPI PAN, tab. 14); „Obsługa była bardzo miła” i „. . . niemiła” mają 0,97. W korpusie wśród 1% najbardziej podobnych par zdań pary POZ–NEG stanowią 15,1% (IPI PAN) i 16,1% (PolEmo), czyli więcej niż wśród wszystkich par (12,5%), a pary o tej samej etykiecie – tyle co przypadkiem (29,1% wobec 30,2%). Najbliższe pary to długie opinie o lekarzach: o podobieństwie decyduje temat, a negacja to tylko jedno słowo w średniej.

2. Zdania podobne znaczeniowo, a odległe, bo użyto innych słów. Częściowo. Parafrazy (0,710) są wyraźnie bliżej niż zdania niepowiązane (0,428), bo Word2Vec zna synonimy (*miła*, *uprzejma*), ale podobieństwo rośnie ze wspólnymi słowami: korelacja Spearmana z miarą Jaccarda zbiorów słów wynosi 0,45 (IPI PAN) i 0,50 (PolEmo), a pary bez wspólnych słów mają średnio 0,62, wobec 0,77 dla par o Jaccardzie powyżej 0,1. Np. „Ogólnie Czystość i pokoje na 10, atmosfera na 3” i „Czysto, schludnie, bardzo wygodne łóżka” są w modelu IPI PAN daleko od siebie (*czystość* i *czysto* to dla niego różne słowa), a w modelu PolEmo blisko.

3. Zdania o różnej długości i podobnym sensie. Nie w pełni: krótkie zdanie i jego długa wersja mają 0,578 (IPI PAN) i 0,658 (PolEmo), mniej niż parafrazy; np. „Polecam .” i długa pochwała hotelu mają 0,50 i 0,60. Dodatkowe słowa długiego zdania (hotel, rodzina, tydzień) odciągają jego wektor od oceny.

Model	Grupa (tokeny)	n	norma	cos do centroidu	śr. cos do innych
Word2Vec IPI PAN	(4.999, 11.333]	67	2,13	0,747	0,612
	(11.333, 20.0]	70	1,93	0,836	0,686
	(20.0, 36.0]	63	1,81	0,885	0,726
	Spearman (tokeny vs. śr. cos)				0,774
Word2Vec PolEmo	(4.999, 11.333]	67	2,35	0,718	0,563
	(11.333, 20.0]	70	2,05	0,800	0,628
	(20.0, 36.0]	63	1,91	0,847	0,665
	Spearman (tokeny vs. śr. cos)				0,757

Tabela 15: Długość zdania a wektor dla uśrednionego Word2Vec: trzy grupy zdań według liczby tokenów (te same co w analizie fastText i USE), średnia norma surowego wektora, podobieństwo do centroidu korpusu i do pozostałych zdań.

4. Długość zdania a wartości podobieństwa i „wyrazistość" wektora. Tak, silniej niż w fastText (tab. 15). Od zdań krótkich do długich norma wektora maleje (2,13 → 1,81 w IPI PAN), podobieństwo do centroidu korpusu rośnie (0,747 → 0,885), a korelacja długości ze średnim podobieństwem do innych zdań wynosi 0,77 i 0,76 (fastText 0,59). Uśrednianie znosi wkłady słów, więc wektor długiego zdania jest mniej wyrazisty i bliski „przeciętnemu zdaniu" – dlatego najbliższe pary w korpusie to głównie długie zdania. Pomogłoby ważenie słów (rzadsze ważniejsze) i usunięcie wspólnej składowej wszystkich zdań.

Model	accuracy	macro-F1	kNN-10	silhouette	recall POZ	recall NEG	recall NEU	recall AMB
Word2Vec IPI PAN	0,505	0,310	0,329	−0,065	0,44	0,07	0,89	0,00
Word2Vec PolEmo	0,540	0,348	0,356	−0,048	0,54	0,11	0,89	0,00
fastText	0,505	0,322	0,321	−0,123	0,33	0,15	0,92	0,00
USE	0,520	0,330	0,334	−0,013	0,50	0,09	0,88	0,00
TF-IDF	0,490	0,318	0,335	−0,008	0,32	0,17	0,88	0,00

Tabela 16: Klasyfikacja wydźwięku zdania na samych osadzeniach (etykiety uzgodnione; ten sam protokół co w tab. 13, baza większościowa 0,415).

5. Czy osadzenia nadają się do zadania? Nie samodzielnie (tab. 16). Accuracy wynosi 0,505 (IPI PAN) i 0,540 (PolEmo) przy bazie większościowej 0,415; klasyfikator wybiera głównie NEU (czułość 0,89), NEG rozpoznaje rzadko (0,07 i 0,11), a AMB wcale. Model PolEmo wypada najlepiej z pięciu porównanych (macro-F1 0,348), ale uczono go na tym samym korpusie recenzji, z którego pochodzą zdania. Uśrednione Word2Vec kodują głównie temat; do rozpoznawania wydźwięku potrzebny jest model uwzględniający kolejność słów i negację.

5 Wnioski

- Zgodność anotatorów jest znaczna na poziomie zdań, a umiarkowana dla zaznaczonych słów. Nowe wytyczne nie poprawiły jej mierzalnie (różnice mieszczą się w przedziałach ufności); poprawa dotyczy głównie klasy NEG oraz słów WYR_NEG i OSL.
- Rozstrzygnięcie konfliktów przesunęło część zdań z etykiet AMB, NEG i POZ korpusu do NEU, zgodnie z regułą „fakt a opinia"; zbiór uzgodniony jest niezrównoważony (dominuje NEU, AMB jest rzadkie).
- Testowane osadzenia zdań kodują głównie temat i słownictwo, a słabo wydźwięk: zdania o przeciwnym sensie bywają bliższe niż parafrazy, a klasyfikator na samych osadzeniach niewiele przewyższa bazę większościową.

- Porównując podobieństwa, trzeba uwzględniać długość zdań (uśrednianie zbliża długie zdania do wektora średniego) oraz skalę modelu (USE ma niższe wartości niż fastText).
- Uśrednione wektory Word2Vec zachowują się podobnie do fastText: zdania o przeciwnym sensie są bliższe niż parafrazy, a długość zdania silnie zbliża je do wektora średniego (korelacja 0,77). Model uczony na recenzjach PolEmo daje najwyższą accuracy z pięciu modeli (0,540), ale nadal tylko nieco wyższą od bazy większościowej (0,415).
- Osadzenia word2vec dobrze pokrywają słownictwo korpusu (model IPI PAN zna 94,6% słów) i oddają znaczenie ogólne, ale słabo wydźwięk: antonimy leżą blisko, a słowa pozytywne i negatywne nie tworzą skupisk (sylwetka 0,033); wydźwięk da się jednak częściowo odczytać prostym klasyfikatorem (trafność 0,72).
- Model ogólny i model uczony na recenzjach dają niemal rozłączne listy najbliższych słów (9% wspólnych sąsiadów): pierwszy relacje słownikowe (synonimy, antonimy), drugi skojarzenia tematyczne, ale z szumem dla rzadkich słów.
- Do zadań związanych z wydźwiękiem potrzebna jest adaptacja do dziedziny i wiedza o wydźwięku (np. retrofitting) albo modele kontekstowe.

Wykorzystanie narzędzi opartych na modelach językowych

Anotatorzy A1 i A2 nie korzystali z modeli językowych (zgodnie z wytycznymi). W pozostałych częściach pracy korzystano z asystenta opartego na modelu językowym (Claude, Anthropic), przy następujących zadaniach: napisanie kodu i notebooka do osadzeń zdań (fastText, Universal Sentence Encoder, TF-IDF, t-SNE, klasyfikator, miary jakości; `src/text_embeddings.py`, `notebooks/Text_Embeddings.ipynb`); przygotowanie placeholderów na odpowiedzi na pytania pomocnicze do części Text Embeddings oraz szablonu sprawozdania w LaTeX wraz ze skryptem generującym tabele i rysunki z plików repozytorium. W części Word Embeddings: napisanie kodu do osadzeń słów, wizualizacji t-SNE, list najbliższych słów i ich porównania oraz generowania tabel do sprawozdania (`src/word_embeddings.py`, `src/word_tsne.py`, `src/word_neighbours.py`, `src/word_report.py`), a także szkicu dyskusji (`report/sections/we_dyskusja.tex`). W części Text Embeddings dla uśrednionego Word2Vec: osadzenia zdań, wykresy t-SNE, analiza do pytań pomocniczych i generowanie tabel (`src/text_analysis.py`, `src/text_report.py`) oraz szkic odpowiedzi (`report/sections/te_w2v.tex`). Generowane części zostały sprawdzone przez autorów, a ostateczne decyzje zatwierdzili autorzy.

Literatura

[1] J. Cohen, *A coefficient of agreement for nominal scales*, Educational and Psychological Measurement 20(1), 1960.

[2] J. L. Fleiss, *Measuring nominal scale agreement among many raters*, Psychological Bulletin 76(5), 1971.

[3] J. R. Landis, G. G. Koch, *The measurement of observer agreement for categorical data*, Biometrics 33(1), 1977.

[4] J. Kocoń, P. Miłkowski, M. Zaśko-Zielińska, *Multi-level sentiment analysis of PolEmo 2.0*, CoNLL 2019.

[5] P. Bojanowski, E. Grave, A. Joulin, T. Mikolov, *Enriching word vectors with subword information*, TACL 5, 2017.

[6] D. Cer et al., *Universal Sentence Encoder*, arXiv:1803.11175, 2018.

[7] T. Mikolov, K. Chen, G. Corrado, J. Dean, *Efficient estimation of word representations in vector space*, arXiv:1301.3781, 2013.

[8] Instytut Podstaw Informatyki PAN, *Modele dystrybucyjne dla języka polskiego (word2vec; pełny NKJP i polska Wikipedia z końca 2016 r.)*, http://dsmodels.nlp.ipipan.waw.pl (dostęp: 20.10.2026).

[9] M. Faruqui, J. Dodge, S. K. Jauhar, C. Dyer, E. Hovy, N. A. Smith, *Retrofitting word vectors to semantic lexicons*, NAACL-HLT 2015.